



Investigación sobre el proceso de trabajo con Machine Learning

*Diseño Centrado en Usuarios - INF337
Proyecto 2 - 02 de Diciembre del 2022
UTFSM - CC*

<i>Tabla de contenidos</i>	<i>Página</i>
1. Definición del problema	1
2. Usuarios y audiencia	2
3. Roles y responsabilidades	2
4. Alcance y restricciones	2
5. Proceso	3
6. Resultados	
a. Investigación contextual	5
b. Evidencia Problem Statement	5
c. Problem starter	7
d. User Persona	8
e. Escenario de uso y mapa de escenarios	8
f. Prototipos	11
g. Discusión	12
7. Anexo	
Tabla de tiempos	14
Creative Matrix	14

1. Definición del problema

Machine Learning (ML) se puede definir como “una forma de la Inteligencia Artificial (IA) que permite a un sistema aprender de los datos en lugar de aprender mediante programación explícita” ¹. Se utiliza para crear **modelos a partir de ciertos datos, con los cuales se pueden hacer predicciones**. Para lograr esto, es importante que quien esté programando en este ámbito sepa de los modelos que puede implementar en un conjunto de datos, conozca los datos más apropiados y use los algoritmos correctos. *Sin embargo, no es un proceso fácil llegar, sobre todo para alguien que no esté familiarizado en este tipo de programación.*

Para hacer el trabajo anterior menos tedioso, el **Centro Nacional de Inteligencia Artificial** (CENIA) está construyendo una **interfaz gráfica interactiva** que permita realizar de forma más rápida las configuraciones necesarias de los modelos en ML y así encontrar el algoritmo adecuado para cada caso. No obstante, esta plataforma **no ha seguido un diseño centrado en personas**, por lo que es incierto si esta herramienta puede lograr su objetivo de hacer más simple el trabajo de una persona que está experimentando con ML.

Dado lo anterior, en este proyecto se optó por **realizar investigaciones contextuales** a estudiantes que ya tengan experiencia en el campo de ML, para así **conocer sus necesidades o problemas** que surgen cuando programan en este ámbito. Con estas experiencias se busca responder a la pregunta:

*¿Cómo podríamos nosotros crear una herramienta
que facilite el proceso de experimentación en Machine Learning?*

¹ <https://www.ibm.com/cl-es/analytics/machine-learning>

2. Usuarios y audiencia

Al resolver el problema de crear una herramienta que facilite el proceso de experimentación en Machine Learning, los usuarios afectados **directamente** serían los **estudiantes** que utilizarían esta herramienta para aprender de manera experimental los procesos que se realizan al momento de crear y entrenar (además de todos sus pasos indirectos) un modelo de Machine Learning, esto incluyendo modelos de machine learning puros, como también sus derivados (redes neuronales, deep learning, etc). Además, existe otro grupo de usuarios que se podrían beneficiar **directamente** de esta herramienta, estos son los **usuarios experimentados** en Machine Learning que realizan modelos de manera regular, ya sea debido a su trabajo o proyecto personal, estos usuarios utilizarían esta herramienta para facilitar las modificaciones que constantemente deben realizar en sus datos y modelos para así obtener los mejores resultados.

Por otro lado, los usuarios afectados **indirectamente** serían los **profesores**, los cuales tendrían una forma más visual de demostrar a sus alumnos los efectos que generan los cambios de datos o parámetros dentro de un modelo de Machine Learning.

3. Roles y responsabilidades

El equipo es compuesto por cuatro integrantes, desarrollando las siguientes acciones:

- **Francisco Aspe:** Mediador en Abstraction Laddering.
- **Rodrigo Cayazaya:** Mediador en Scenario Mapping.
- **Javier Torres:** Mediador Problem Starters
- **Víctor Morales:** Mediador en Diagrama de afinidad

Se destaca que cada integrante realizó una entrevista contextual, tomando sus observaciones AEIOU, además de participar en la redacción del presente informe.

4. Alcance y restricciones

Alcance:

Cada integrante del equipo realizó una investigación contextual a un estudiante que ya tuviera experiencia con machine learning. Cabe destacar que no se observó a la misma persona dos veces. El presupuesto para realizar las investigaciones fue nulo, ya que fueron realizadas de forma online a través de videollamada y junto con la generosidad de los entrevistados, permitieron que no se incurriera en gastos extras.

En cuanto al tiempo dedicado aproximado en horas por método, invertimos (como equipo) en total 2 con el Problem Statement, 2 referente al Diagrama de afinidad, 1 con la Creative Matrix, al igual que el User persona, 2 horas al Escenario Mapping y también 2 para el prototipado . Para más detalles revisar [tabla de tiempos](#) en anexos.

Restricciones:

- Tiempo limitado para conseguir usuarios para la investigación contextual, lo que produjo que no existiera mucha diversidad en el tipo de individuo.
- Realización de la investigación contextual vía online con pantalla compartida, pudiendo

provocar que los usuarios no realicen las mismas acciones, como también omitiendo posibles detalles del ambiente no visibles por esta vía.

5. Proceso

Investigación contextual

Debido a la naturaleza del proyecto, fue necesario encontrar personas que tengan un conocimiento mínimo de Machine Learning para pedirles que realicen un proceso completo de predicción, lo cual incluye el análisis de datos, limpieza de datos, creación del modelo, entrenamiento del modelo y predicción.

Todos los usuarios son o fueron estudiantes de Ingeniería Civil Informática de la Universidad Técnica Federico Santa María del campus San Joaquín (Santiago) y las observaciones se realizaron entre el día 13 y 14 de noviembre.

Para poder visualizar el proceso que los usuarios realizaban, se les pidió que compartieran su cámara y toda su pantalla, a manera de simular una interacción de observación presencial, ya que con esto se podía observar el código, el navegador y sus expresiones faciales.

Análisis, definición de problema y prototipo

Durante la investigación contextual, nos dedicamos a tomar notas de las actividades, entornos, interacciones, objetos y usuarios, mejor conocido como una **observación AEIOU**. El día 14 de noviembre compartimos las observaciones que realizó cada uno y se organizaron para así crear un [diagrama de afinidad](#) en donde reunimos las notas en diferentes categorías para su posterior análisis.

Una vez realizado el análisis de las observaciones, se desarrolló un [problem starter](#) en donde surgieron las siguientes preguntas:

1. ¿Cómo podríamos nosotros facilitar el aprendizaje del machine learning?
2. ¿Cómo podríamos nosotros reducir las barreras de entradas al machine learning?
3. ¿Cómo podríamos nosotros crear una herramienta que facilite el proceso de experimentación en ML?

En donde escogimos la tercera pregunta, ya que es la que mejor se adapta a la problemática que intenta solucionar DashIA, además no es tan amplia como la primera y no se reduce solamente a usuarios nuevos como la segunda. Luego se realizó un [abstraction laddering](#), sin embargo este no fue necesario, ya que nos encontrábamos en un nivel de abstracción ideal con la pregunta anteriormente escogida.

El día 15 de noviembre se realizó una [matriz creativa](#) con el objetivo de encontrar una solución que se pueda prototipar. Para la creación de la matriz utilizamos como filas: IA, Programa, Contenido dinámico y Comodín; como columnas utilizamos: Selección de parámetros, Limpieza de datos, Selección del modelo y Análisis exploratorio de datos. Una vez llenada la matriz con diferentes soluciones, se realizó una votación y se llegó a un empate entre la solución que cruza la fila de Programa con la columna de Selección de parámetros, específicamente “un programa que recomiende o automatice la selección de parámetros” y la solución que cruza la fila de Programa con la columna de Selección del modelo, específicamente “Programa que muestre un listado de los modelos”.

Posteriormente, el día 17 de noviembre, se realizó un [user persona](#) basándonos en el perfil de los usuarios de la investigación contextual. Debido a que todos los usuarios compartían rasgos similares, se decidió solamente realizar 1 user persona. Luego se realizó un [scenari mapping](#)

basándonos en las columnas de la matriz creativa como los pasos a seguir, de este último se desprendieron muchas ideas de diseño que aplicamos en nuestro prototipo.

Por último, el día 21 de noviembre se realizó un [prototipo](#) utilizando la página web InvisionApp donde llevamos a cabo ambas soluciones que empataron en la matriz creativa, pero utilizando las ideas que surgieron en el escenario mapping. Logrando así prototipar 3 vistas que incluyen la elección del modelo y la sintonización de parámetros. Cabe destacar que también tomamos en cuenta las sugerencias que nos entregaron los usuarios sobre cómo ellos mejorarían el proceso.

6. Resultados

a. Investigación contextual

Para iniciar la investigación, se desarrollaron las investigaciones contextuales (vía online Discord) a personas con conocimiento previo en machine learning, en este caso estudiantes de Ing. Civil Informática de la UTFSM, centrándose en el libre desarrollo de un problema del área seleccionado por el mismo participante, el cual además indicaba las actividades/relaciones que realizaba en su máquina.

A continuación se presenta una tabla complementaria de aspectos generales:

<i>Individuo Investigación</i>	<i>Dataset ocupado</i>	<i>Método de resolución</i>	<i>Tiempo aprox. empleado (duración sesión)</i>	<i>Enlace a sesión - (google drive)²</i>
Usuario 1	Clasificación de drogas ³	Regresión lineal	22 minutos	https://drive.google.com/file/d/1wwwl5617Xx4KApG3V_o9CHuGLTTZ_Llw/view?usp=sharing
Usuario 2	Propio de clasificación	Regresión lineal	55 minutos	https://drive.google.com/file/d/12M1r_bvrY67Rm4_VgnP9iyIkBNc3v_/view?usp=share_link
Usuario 3	Clasificación de drogas ³	Redes neuronales	37 minutos	https://drive.google.com/file/d/1ar66GacJMLoSq2nTRqwNg2Zrb7m3b6K7/view?usp=share_link
Usuario 4	Clasificación de drogas ³	Árboles de clasificación	34 minutos	https://drive.google.com/file/d/1fBmovbyAb0OCesbM3J2YUmpc9TD6TpKt/view?usp=share_link

Con la información recabada por cada investigador, tanto de la interacción individuo-problema y consultas realizadas se formó una base de conocimiento, la cual se procedió a analizar siguiendo lo descrito en la sección [5. Proceso](#).

Además, es posible destacar que se distinguieron tareas en común realizadas por los individuos, las cuales sirvieron de base para la identificación de subtarefas y **agrupación de temas en las siguientes secciones**; los mencionados son:

1. *Exploración de dataset*
2. *Limpieza de datos* (mayor tiempo dedicado en sesiones)
3. *Elección y adecuación de modelo* (mayor revisión de material complementario)
4. *Entrenamiento de modelo*
5. *Revisión de resultados, pruebas*

b. Evidencia Problem Statement

Para obtener el problem statement, se hizo primero un diagrama de afinidad con la

² Cabe mencionar que todos los individuos consintieron previamente la grabación de las sesiones.

³ Drug Classification | Kaggle [en línea]: <https://www.kaggle.com/datasets/prathamtripathi/drug-classification>

información obtenida a través de entrevistas con usuarios. A partir de este diagrama se obtuvieron los siguientes clusters:

- **Programación:** contiene personas que trabajan con Machine Learning y son posibles usuarios.
- **Librerías:** contiene elementos relacionados con librerías con las que los entrevistados trabajan.
- **Documentación:** contiene las fuentes de documentación de librerías.
- **Manejo de Código:** contiene métodos que utilizaron los entrevistados para manejar el código que trabajan.
- **Entorno de Trabajo:** contiene elementos del ambiente de trabajo, como lenguaje de programación o sistema operativo.
- **Entorno de Programación:** contiene elementos de Machine Learning.
- **Limpieza de Datos:** contiene las formas en que se realiza la limpieza de datos, como también ciertas frustraciones respecto a este tema.
- **Análisis Exploratorio de Datos:** contiene métodos de análisis, y objetos que contienen datos, como datasets y archivos excel.
- **Búsqueda Información en Base a Experiencia:** contiene sitios web y métodos de búsqueda de información acerca de resolución de problemas o obtención de funciones necesarias.

A partir de la información que se obtuvo de estos clusters se comenzó a trabajar con problem starters y abstraction laddering, llegando al problem statement introducido en la [definición del problema](#).

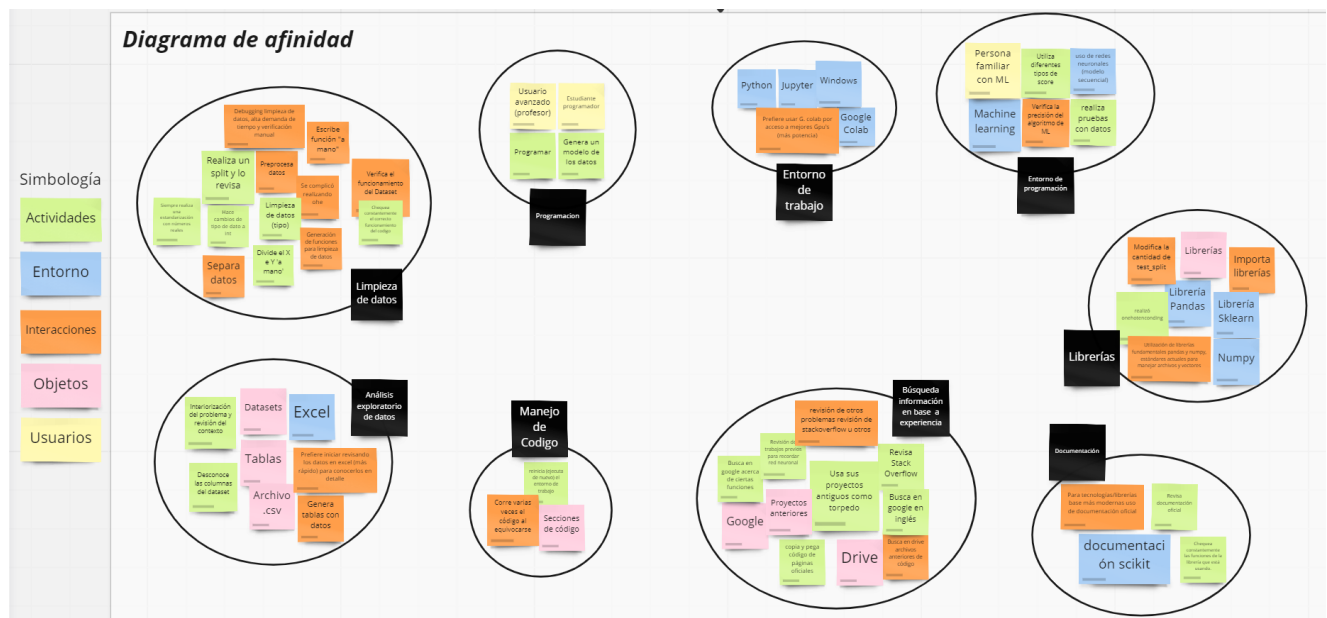


Imagen 1: Diagrama de afinidad elaborado desde el análisis AEIOU, usado para generar el problem statement descrito.

c. Problem starter

Para escoger un problema starter, inicialmente se tomó como punto central el contexto del problema presentado por el Centro Nacional de Inteligencia Artificial (CENIA): “¿Cómo podríamos nosotros reducir las barreras de entradas al machine learning?”, para posteriormente idear alternativas de mayor y menor abstracción y así realizar una votación, donde preliminarmente el resultado escogido fue:

“¿Cómo podríamos nosotros crear una herramienta que facilite el proceso de experimentación en ML?”

Esto debido a que encontramos que se adapta mejor al trabajo ya realizado por el CENIA, el cual se tomó como base para empezar este estudio.

Posteriormente se amplió la idea realizando un abstraction ladderling donde si bien aparecieron más ideas específicas como por ejemplo ¿Cómo podríamos disminuir el tiempo de limpieza de datos y elección de decisiones? O ¿Cómo podríamos ayudar con la elección de herramientas para el proceso?, estas se descartaron ya que acotan demasiado el problema general, pudiendo omitir ideas importantes para pasos contiguos del proceso de resolución. Así se escogió por dejar el problem starter preliminar como el definitivo.

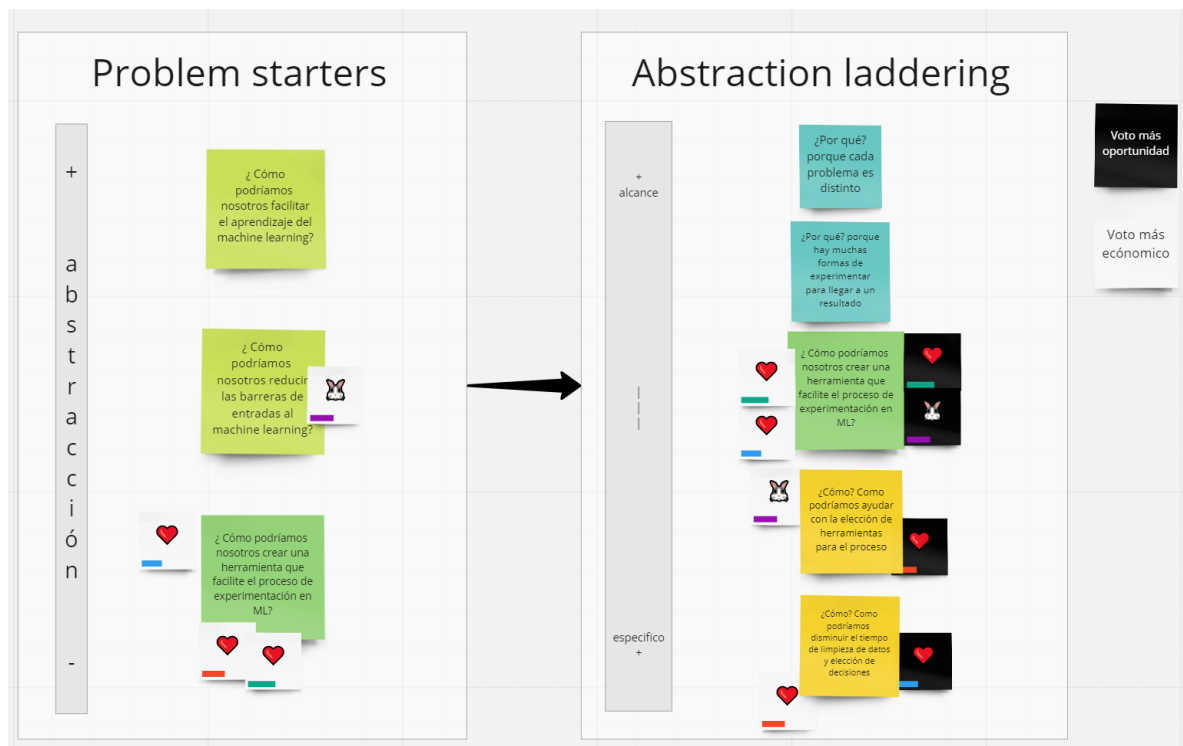


Imagen 2: Elección del Problem starter

Cabe mencionar que el ya tener un contexto/solución entregada, generó una limitación con este método para elegir otras alternativas ligadas al punto central; sin embargo no se tomó como un problema, sino una guía para seguir desarrollando la idea a profundidad.

d. User Persona

A partir de las entrevistas hechas se construyó una User Persona a la cual se le llamó Ricardo Jara. Esta persona corresponde a un estudiante universitario chileno de alrededor de 24 años con experiencia sobre la media en temas de Machine Learning. Tiene alta experiencia en programación y afinidad tecnológica, sin embargo su mala memoria ocasiona que frecuentemente olvide funciones necesarias para hacer su trabajo. A este usuario le gustaría poder trabajar de manera rápida y cómoda sin tener que preocuparse de manejar la limpieza de datos manualmente.

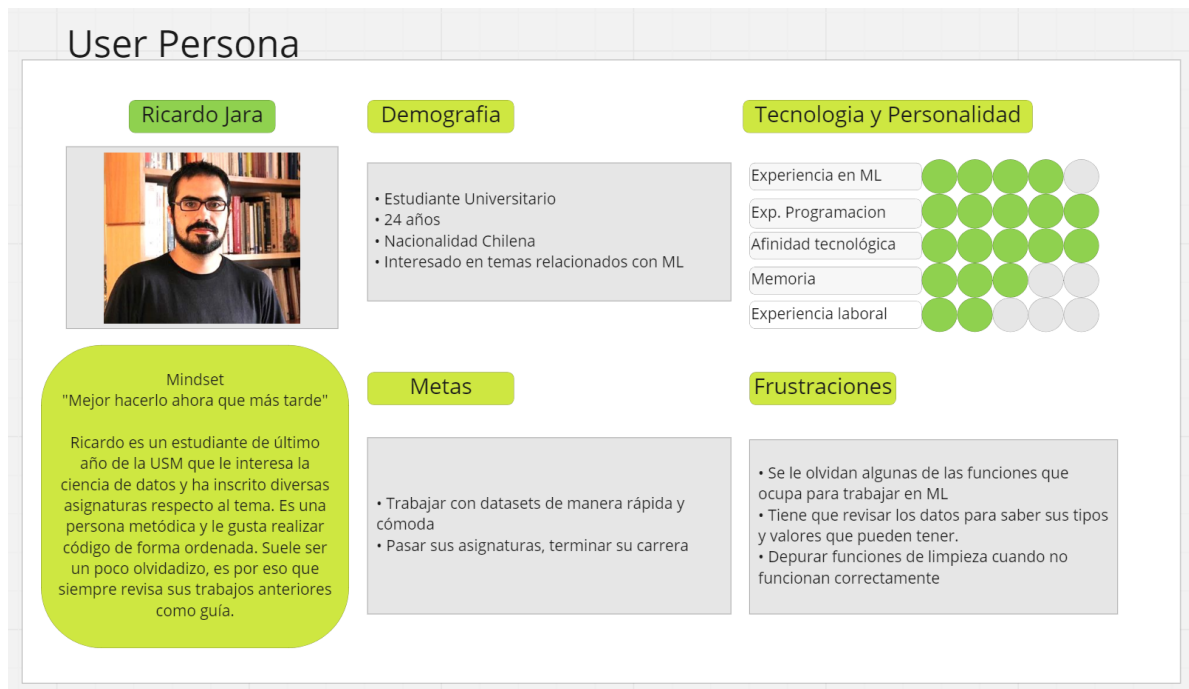


Imagen 3: User persona desarrollado

e. Escenario de uso y mapa de escenarios

Para el escenario de uso, se definieron los pasos mediante las tareas comunes encontradas durante el proceso de resolución de un problema de ML, mencionadas en la sección [6a. investigación contextual](#).

Posterior a ello se dio un tiempo para plantear individualmente preguntas, comentarios e ideas referentes a cada paso explicitado en el flujo, para luego explicar y unir las similares, llegando al siguiente mapeo de escenarios.

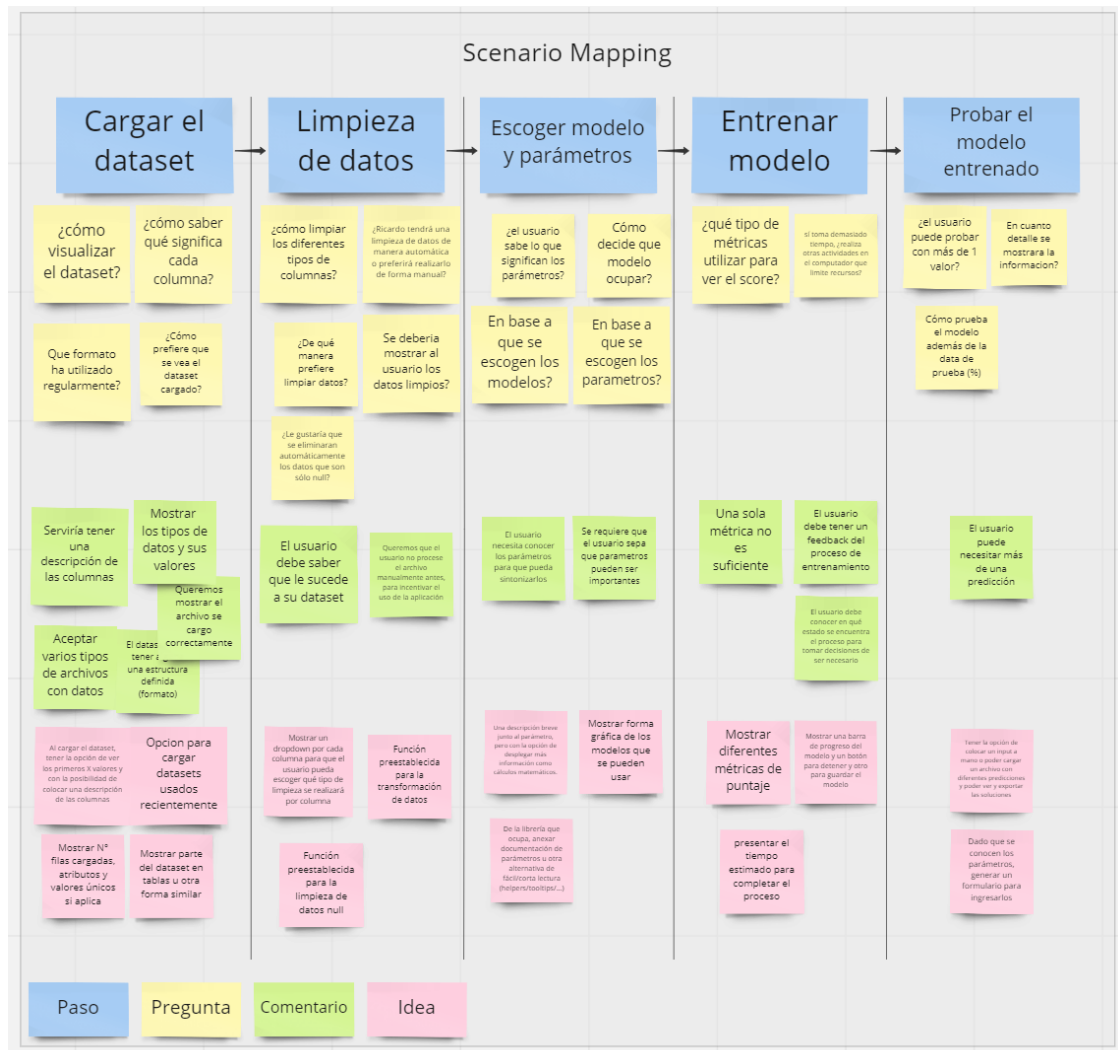


Imagen 4: Escenario (pasos) junto a su mapeo de preguntas, comentarios e ideas.

Desde esta, se logró identificar asuntos que no quedaron claro en las sesiones, o que no se pensaron en el momento, los cuales se podrían **preguntar** en una posterior iteración, ejemplos son:

1. **Carga y exploración de dataset**
 - a. ¿Qué formato (dataset) ha utilizado regularmente?
2. **Limpieza de datos**
 - a. ¿El usuario quiere una limpieza de datos de manera automática o preferirá realizarlo de forma manual?
 - b. ¿Le gustaría que se eliminarán automáticamente los datos que son sólo null?
3. **Escoger modelo y parámetros**
 - a. ¿En base a que se escoge el modelo utilizado?
4. **Entrenar el modelo**
 - a. ¿Qué tipo de métricas utilizar para ver el score?

5. *Probar el modelo*

- a. ¿Cómo prueba el modelo?, además del porcentaje de aprobación del subconjunto de pruebas

También fue útil para identificar lo que el sistema debe ser capaz de proveer (**comentarios**), algunos destacables, por ejemplo, fueron:

1. *Carga/exploración de dataset*

- a. El usuario desea ver los tipos de datos y sus valores

2. *Limpieza de datos*

- a. Queremos que el usuario no procese el archivo manualmente antes, para incentivar el uso de la aplicación
- b. El usuario debe saber que le sucede a su dataset

3. *Escoger el modelo y parámetros*

- a. El usuario necesita conocer los parámetros para que pueda sintonizarlos

4. *Entrenar el modelo*

- a. El usuario debe tener un feedback del proceso de entrenamiento

5. *Probar el modelo*

- a. El usuario puede necesitar más de una predicción

Finalmente con lo anterior se pudo identificar mejoras específicas para la interfaz, **ideas** propuestas que pueden ayudar al usuario a tener una mejor experiencia, algunas de ellas fueron:

1. *Carga/exploración de dataset*

- a. Opción para cargar datasets usados recientemente
- b. Mostrar N° filas cargadas, atributos y valores únicos si aplica

2. *Limpieza de datos*

- a. Mostrar un dropdown por cada columna, para que el usuario pueda escoger qué tipo de limpieza se realizará en cada una
- b. Función preestablecida para la limpieza de datos null

3. *Escoger el modelo y parámetros*

- a. Mostrar forma gráfica de los modelos que se pueden usar
- b. De la librería que ocupa, anexar documentación de parámetros u otra alternativa de fácil/corta lectura (helpers/tooltips/...)

4. *Entrenar el modelo*

- a. Mostrar una barra de progreso del modelo y un botón para detener y otro para guardar el modelo.

5. *Probar el modelo*

- a. Tener la opción de colocar un input a mano o poder cargar un archivo con diferentes predicciones y poder ver y exportar las soluciones.

A partir de estas últimas, junto a ideas provenientes de la matriz creativa se realizaron los prototipos detallados en la siguiente sección.

f. Prototipos

De los pasos anteriores realizados, se generaron los siguientes prototipos:



Imagen 5: Prototipos de interfaces desarrollados en InVisionApp.

Estos prototipos fueron realizados en base al [Scenario Mapping](#), específicamente de la sección “*Escoger modelo y parámetros*”. Como se puede observar en las imágenes, se han implementado las ideas que se expusieron en tal sección:

- En la primera imagen se muestra la implementación de mostrar una forma gráfica de los modelos que se pueden usar. En este caso se muestra una figura gráfica estándar de cada modelo, para poder identificarlo de mejor manera.
- En la tercera imagen se puede observar la implementación de la descripción breve de los parámetros, al tener un símbolo de información en cada parámetro y desplegar más información en un cuadro de texto al poner el clic encima.

Además, se implementaron otras soluciones adicionales en base al [Creative Matrix](#), tales como:

- En la primera imagen se implementa la solución de mostrar una lista con los modelos más comunes en Machine Learning, de la sección selección del modelo.
- En la segunda imagen se observa la implementación de contenido informativo para el modelo escogido. A pesar de que no aparece en el Creative Matrix en la sección del modelo, encontramos útil mostrar en detalle el modelo a escoger, para que el usuario sepa con más claridad cómo funciona y sus características principales.
- En la tercera imagen se muestra la solución de recomendar cantidad de parámetros estándar, de la sección selección de parámetros.

g. Discusión

Debido a las observaciones, logramos entender cómo el usuario realiza un ejercicio de Machine Learning y todos sus pasos, además de entender cuál es el proceso mental que lleva al usuario a tomar diferentes decisiones y, bajo este contexto, generar propuestas de mejora al procedimiento actual. Es por esto que el entendimiento del usuario nos ayudó al momento de realizar prototipos, ya que pensamos directamente en las soluciones e ideas que encontramos en nuestros análisis, además de ahorrarnos tiempo, ya que sin el entendimiento del usuario hubiéramos creado un prototipo o programa que realmente no le agregue valor al usuario final.

Durante la planificación y el desarrollo investigativo, los inconvenientes que pudieron haber resultado en una mejora del estudio fue principalmente la deficiencia de tiempo inicial para coordinar sesiones de investigación contextual, junto a la nula variedad de tipos de usuarios en estas, ya que todos poseían un perfil similar (estudiantes universitarios Ing. Civil Informática UTFSM); si bien eso aportó en gran medida a un user persona detallado, pudo haber coartado otras perspectivas para mejorar el proceso, como por ejemplo el de un usuario sin mucha experiencia, o iniciando su aprendizaje en ML.

7. Anexo

i. Miro Board con desarrollo de diagramas y otros.

https://miro.com/app/board/uXjVPDxWn_Y=?share_link_id=1923640287

ii. Carpeta con grabaciones de investigación contextual desarrollada

https://drive.google.com/drive/folders/13po0mt3s0UFDLsQ9X8Ph2fASqOtnaHoV?usp=share_link

Tabla de tiempos

Tiempo [hrs]	Francisco Aspe	Rodrigo Cayazaya	Víctor Morales	Javier Torres	Total
Investigación Contextual + AEIOU	0.5	1	0.5	0.5	2.5
Diagrama de afinidad	2	2	2	2	8
Problem Statement	2	2	2	2	8
Matriz creativa	1	1	1	1	4
User persona	1	1	1	1	4
Scenario Mapping	2	2	2	2	8
Prototipo InVision	2	2	2	2	8
Total	10.5	11	10.5	10.5	42.5

Creative Matrix

